

Laporan Kemajuan Proyek Pembelajaran Mesin

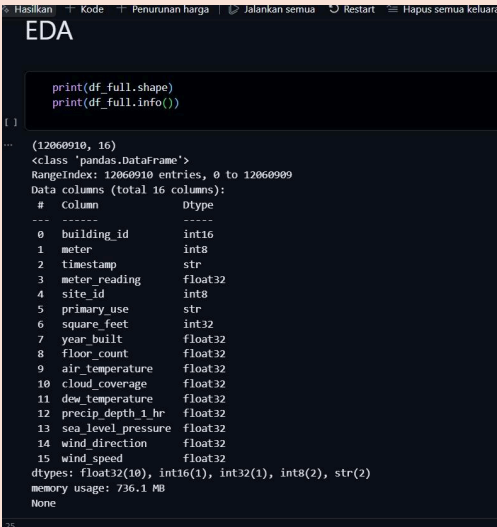
S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024 C
Ketua	Rebriane Atitha Ginting (24031554039)
Anggota 1	Nabilah Hilmi Rosanti (24031554053)
Anggota 2	Kekila Akmal Nifcky
URL Github	atithagt/UAS-Pembelajaran-Mesin-Kelompok-13

Informasi Umum Proyek

Judul	Prediksi Konsumsi Energi Bangunan Menggunakan Random Forest dan XGBoost untuk Mendukung Efisiensi Energi dalam Transisi Energi
Topik	Energi
Pilihan Rumusan Masalah	3.4. Pengembangan Inovasi dan Transformasi Bisnis dalam Transisi Energi
Revisi?	Ya / Tidak

Informasi Detil Dataset

Sumber dataset	Kaggle, ASHRAE - Great Energy Predictor III https://www.kaggle.com/c/ashrae-energy-prediction
Deskripsi awal fitur dataset	Dataset berisi data pembacaan meter energi bangunan per jam, metadata bangunan, dan data cuaca. File yang digunakan meliputi train.csv, building_metadata.csv, dan weather_train.csv. Target prediksi adalah meter_reading. Fitur dataset meliputi building_id, meter, timestamp, meter_reading, site_id, primary_use, square_feet, year_built, floor_count, air_temperature, cloud_coverage, dew_temperature, precip_depth_1_hr, sea_level_pressure, wind_direction, dan wind_speed.
EDA	Sebelum EDA, dataset awal yang berjumlah sekitar 20 juta baris disaring menjadi sekitar 9 juta baris sesuai kebutuhan analisis. Kami juga menerapkan memory reduction agar proses pengolahan data lebih efisien dan tidak membebani memori perangkat.  <pre>EDA print(df_full.shape) print(df_full.info()) (12060910, 16) <class 'pandas.DataFrame'> RangeIndex: 12060910 entries, 0 to 12060909 Data columns (total 16 columns): # Column Dtype --- - 0 building_id int16 1 meter int8 2 timestamp str 3 meter_reading float32 4 site_id int8 5 primary_use str 6 square_feet int32 7 year_built float32 8 floor_count float32 9 air_temperature float32 10 cloud_coverage float32 11 dew_temperature float32 12 precip_depth_1_hr float32 13 sea_level_pressure float32 14 wind_direction float32 15 wind_speed float32 dtypes: float32(10), int16(1), int32(1), int8(2), str(2) memory usage: 736.1 MB None</pre>

Gambar 1. Cek Data

Dari Gambar 1 terlihat bahwa data konsumsi energi, metadata bangunan, dan data cuaca digabungkan, diperoleh dataset sebanyak 12.060.910 baris dan 16 variabel. Analisis difokuskan pada konsumsi energi listrik dengan memilih meter = 0, karena listrik paling relevan dengan operasional bangunan modern, seperti AC, pencahayaan, dan perangkat elektronik. Dataset ini mencakup karakteristik bangunan serta kondisi cuaca yang berpotensi memengaruhi pola konsumsi energi.


```

floor_count      75.417883
year_built       53.644667
cloud_coverage   44.189468
precip_depth_1_hr 20.841537
sea_level_pressure 8.443666
wind_direction   5.627395
wind_speed       0.553814
dew_temperature  0.407026
air_temperature  0.392383
square_foot      0.000000
site_id          0.000000
primary_use      0.000000
meter            0.000000
timestamp        0.000000
building_id      0.000000
meter_reading    0.000000
dtype: float64


```

Gambar 2. Identifikasi Missing Value

Pada Gambar 2 terlihat hasil identifikasi missing value menunjukkan bahwa variabel `floor_count` memiliki data kosong tertinggi sebesar 75,4%, diikuti `year_built` sebesar 53,6%, dan `cloud_coverage` sebesar 44,2%. Variabel dengan missing value sangat tinggi seperti `floor_count` dipertimbangkan untuk dihapus, sedangkan `year_built` serta variabel cuaca dengan data hilang rendah, seperti `air_temperature`, `dew_temperature`, dan `wind_speed` (<1%), diimputasi menggunakan median agar distribusi data tetap stabil dan informasi penting tetap dipertahankan.



Gambar 3. Histogram Distribusi




Gambar 4. Histogram Log Distribusi

Gambar 3 menunjukkan histogram `meter_reading` dengan distribusi sangat right-skewed. Sebagian besar data berada pada konsumsi energi rendah, sedangkan sebagian kecil memiliki nilai sangat tinggi. Gambar 4 menunjukkan distribusi `meter_reading` setelah transformasi `log1p`. Hasilnya lebih stabil dan menyebar, sehingga transformasi log layak digunakan pada tahap preprocessing untuk mengurangi pengaruh nilai ekstrem.


	air_temperature	dew_temperature	wind_speed	sea_level_pressure
count	1.201358e+07	1.201182e+07	1.199412e+07	1.104253e+07
mean	1.600965e+01	8.334991e+00	3.559324e+00	1.016408e+03
std	1.039774e+01	9.836796e+00	2.317835e+00	7.035792e+00
min	-2.890000e+01	-3.500000e+01	0.000000e+00	9.682000e+02
25%	8.900000e+00	1.100000e+00	2.100000e+00	1.012100e+03
50%	1.670000e+01	9.400000e+00	3.100000e+00	1.016500e+03
75%	2.390000e+01	1.610000e+01	4.600000e+00	1.020700e+03
max	4.720000e+01	2.610000e+01	1.900000e+01	1.045500e+03

Gambar 5. Statistik Deskriptif Cuaca


Statistik deskriptif menunjukkan bahwa variabel cuaca cukup beragam. `air_temperature` memiliki median 16,7°C dengan rentang -28,9°C hingga 47,2°C, sedangkan `dew_temperature` memiliki median 9,4°C. `wind_speed` cenderung rendah dengan median 3,1, dan `sea_level_pressure` relatif stabil di sekitar 1016 hPa. Temuan ini menunjukkan bahwa data cuaca bersifat heterogen dan belum sepenuhnya merepresentasikan iklim tropis Indonesia.




Gambar 6. Histogram Distribusi Air



Gambar 7. Histogram Distribusi Dew



Gambar 8. Histogram Distribusi Sea





Gambar 9. Histogram Distribusi Wind

Gambar 6 hingga Gambar 9 menunjukkan distribusi variabel cuaca yang beragam. *air_temperature* dan *dew_temperature* terkonsentrasi pada suhu sedang, tetapi masih memiliki nilai ekstrem yang menunjukkan adanya wilayah non-tropis. *wind_speed* memiliki distribusi right-skewed, dengan mayoritas nilai berada pada kecepatan rendah hingga sedang. Sementara itu, *sea_level_pressure* relatif stabil dan terkonsentrasi di sekitar 1010–1020 hPa.


```
primary_use
Education      4597256
Office         2310203
Entertainment/public assembly 1511295
Public services 1320045
Lodging/residential 1229082
Other          210764
Parking        187447
Healthcare     184345
Warehouse/storage 103077
Retail         96618
Manufacturing/industrial 85216
Services       78951
Technology/science 45275
Food sales and service 43826
Utility        32476
Religious worship 25034
Name: count, dtype: int64
```

Gambar 10. Statistik Deskriptif *Primary_use*


Pada Gambar 10 terlihat bahwa distribusi *primary_use* didominasi oleh Education, lalu Office, Entertainment/Public Assembly, Public Services, dan Lodging/Residential. Hal ini menunjukkan bahwa dataset banyak merepresentasikan bangunan dengan aktivitas operasional tinggi dan penggunaan listrik rutin.



Gambar 11. Bar Chart Konsum Energi



Gambar 12. Line Chart Konsum Energi Jam



Gambar 13. Line Konsum Energi Bulan

Gambar 14. Bar Konsum Energi Hari

Gambar 11 hingga Gambar 14 menunjukkan bahwa konsumsi energi berbeda berdasarkan fungsi bangunan, jam, bulan, dan hari. Rata-rata konsumsi tertinggi terdapat pada kategori Healthcare, Education, Utility, dan Office karena aktivitas operasionalnya tinggi. Konsumsi juga meningkat pada siang hingga sore hari, naik pada pertengahan tahun terutama sekitar Agustus–September, serta cenderung lebih tinggi pada hari kerja dibanding akhir pekan. Pola ini menunjukkan bahwa penggunaan listrik dipengaruhi oleh jenis bangunan, waktu operasional, dan variasi musiman.

	meter_reading	floor_count	square_feet	air_temperature	dew_temperature	wind_speed	sea_level_pressure
meter_reading	1.000000	0.349708	0.522051	0.026839	0.043710	-0.019410	-0.007885
floor_count	0.349708	1.000000	0.505747	-0.297851	-0.256773	0.093124	-0.103812
square_feet	0.522051	0.505747	1.000000	0.015655	-0.014999	-0.042020	-0.047269
air_temperature	0.026839	-0.297851	0.015655	1.000000	0.283012	-0.019220	-0.248257
dew_temperature	0.043710	-0.256773	-0.014999	0.283012	1.000000	-0.110167	0.066523
wind_speed	-0.019410	0.093124	-0.042020	-0.019220	-0.110167	1.000000	-0.144317
sea_level_pressure	-0.007885	-0.103812	-0.047269	-0.248257	0.066523	-0.144317	1.000000

Gambar 15. Tabel Korelasi

Gambar 15 menunjukkan bahwa *square_feet* memiliki korelasi positif sedang terhadap *meter_reading* sebesar 0,55. Artinya, semakin besar luas bangunan, konsumsi energi cenderung semakin tinggi. Sementara itu, variabel cuaca memiliki korelasi linear yang lemah, sehingga pengaruhnya kemungkinan bergantung pada kombinasi faktor lain seperti waktu, jenis bangunan, dan aktivitas operasional.

Pada tahap preprocessing, dilakukan filtering suhu udara untuk menyesuaikan dataset dengan konteks iklim Indonesia. Filtering ini menggunakan variabel *air_temperature* dengan rentang 15–40°C agar data lebih relevan dengan karakteristik wilayah tropis.

Detil-detil
langkah
pre-processing

```
Pre-Processing

Filtering Relevansi Indonesia

df_full['air_temperature'].quantile(
    [0.01, 0.05, 0.10, 0.25, 0.50, 0.75, 0.90, 0.95, 0.99]
)

0.01    -10.000000
0.05     -1.700000
0.10     2.200000
0.25     8.900000
0.50    16.700001
0.75    23.900000
0.90    28.900000
0.95    31.700001
0.99    37.200001
Name: air_temperature, dtype: float32
```

Before : 12060910
After : 6739305
Remain : 55.88 %

Gambar 16. Hasil kuantil *air_temperature*.

Gambar 17. Hasil Filtering

Gambar 16 dan 17 menunjukkan hasil filtering *air_temperature* Nilai kuantil menunjukkan bahwa 1% data memiliki suhu di bawah -10°C , median suhu berada pada $16,7^{\circ}\text{C}$, dan 99% data berada di bawah $37,2^{\circ}\text{C}$. Temuan ini mengindikasikan bahwa sebagian besar data tidak sepenuhnya merepresentasikan kondisi iklim tropis Indonesia karena masih banyak observasi dengan suhu rendah khas wilayah beriklim

dingin. Oleh karena itu, pada tahap preprocessing dilakukan filtering suhu pada rentang 15–40°C agar dataset lebih relevan dengan karakteristik bangunan di Indonesia. Rentang tersebut dipilih untuk tetap mengakomodasi wilayah dataran tinggi Indonesia, namun mengurangi dominasi data dari wilayah non-tropis. Setelah filtering, sekitar 55,88% data atau sekitar 6,7 juta observasi tetap dipertahankan, sehingga dataset masih cukup besar untuk proses pemodelan.

	timestamp	hour	dayofweek	month
0	2016-01-01	0	4	1
1	2016-01-01	0	4	1
2	2016-01-01	0	4	1
3	2016-01-01	0	4	1
4	2016-01-01	0	4	1

Gambar 18. Tabel Feature Engineering

Gambar 18 menunjukkan tahap feature engineering dengan mengekstraksi variabel timestamp menjadi fitur baru, yaitu hour, dayofweek, dan month. Fitur ini digunakan agar model dapat mengenali pola konsumsi energi berdasarkan jam penggunaan, perbedaan hari, serta variasi bulanan atau musiman.

primary_use_Education	2491945
primary_use_Entertainment/public assembly	894823
primary_use_Food sales and service	25806
primary_use_Healthcare	88217
primary_use_Lodging/residential	737772
primary_use_Manufacturing/industrial	31444
primary_use_Office	1212248
primary_use_Other	144327
primary_use_Parking	125898
primary_use_Public services	762278
primary_use_Religious worship	14484
primary_use_Retail	63336
primary_use_Services	49495
primary_use_Technology/science	17951
primary_use_Utility	17537
primary_use_Warehouse/storage	61744
dtype: int64	

Gambar 19. Hasil Encoding

Gambar 19 menunjukkan proses One-Hot Encoding pada variabel kategorikal primary_use. Proses ini mengubah jenis fungsi bangunan, seperti Education, Office, Healthcare, dan kategori lainnya menjadi format numerik agar dapat diproses oleh model Random Forest dan XGBoost. Selanjutnya pada tahap preprocessing, variabel target meter_reading ditransformasi menggunakan log1p untuk mengurangi distribusi yang right-skewed. Transformasi ini membantu menekan pengaruh outlier, menangani nilai nol, dan membuat target lebih stabil untuk proses pemodelan.

```
(6739305, 30)
(6739305,)
```

Gambar 20. Hasil Split Feature Target

Pada gambar 20 tahap ini, data dipisahkan menjadi feature (X) dan target (y). Feature berisi variabel prediktor, sedangkan target berisi meter_reading_log yang akan diprediksi. Variabel meter_reading dan meter_reading_log dihapus dari X untuk mencegah data leakage, yaitu kondisi ketika model mendapat informasi target secara langsung. Hasil pemisahan data menunjukkan bahwa X berukuran (6.739.305, 30) dan y berukuran (6.739.305,), artinya terdapat 6.739.305 data, 30 fitur prediktor, dan 1 target prediksi.

Kemajuan Pengerjaan

Teknik yang digunakan	Proyek ini menggunakan teknik supervised learning dengan pendekatan regresi, karena target yang diprediksi berupa nilai numerik, yaitu meter_reading atau konsumsi energi listrik bangunan. Algoritma yang digunakan adalah Random Forest Regressor dan XGBoost Regressor. Random Forest digunakan sebagai model ensemble berbasis bagging, sedangkan XGBoost digunakan sebagai model ensemble berbasis boosting. Kedua algoritma ini dipilih karena cocok untuk data tabular, mampu menangani pola non-linear, serta dapat digunakan untuk membandingkan performa prediksi konsumsi energi bangunan.																																																								
Nilai metrik terakhir	Pada tahap pelatihan model, digunakan dua algoritma regresi yaitu Random Forest Regressor dan XGBoost Regressor untuk memprediksi konsumsi energi bangunan. Karena penelitian ini termasuk kasus regresi, maka metrik evaluasi yang digunakan bukan Accuracy dan F1-Score, melainkan MAE (Mean Absolute Error), RMSE (Root Mean Square Error), dan R² Score. 1. Hasil Random Forest Regressor Pengujian awal dilakukan menggunakan beberapa kombinasi hyperparameter Random Forest. <table><tr><th>Parameter</th><th>MAE</th><th>RMSE</th><th>R²</th></tr><tr><td>P1 (30 trees, depth=15)</td><td>0.3518</td><td>0.6299</td><td>0.8731</td></tr><tr><td>P2 (50 trees, depth=20)</td><td>0.2101</td><td>0.4569</td><td>0.9332</td></tr><tr><td>P3 (15 trees, depth=8)</td><td>0.6338</td><td>0.9497</td><td>0.7116</td></tr></table> Berdasarkan hasil tersebut, parameter terbaik diperoleh pada P2 dengan n_estimators = 50 dan max_depth = 20. Model menghasilkan nilai MAE sebesar 0,2101, RMSE sebesar 0,4569, dan R² sebesar 0,9332. Nilai R² yang mendekati 1 menunjukkan bahwa model mampu menjelaskan sekitar 93,32% variasi data konsumsi energi. Hasil evaluasi train dan test menunjukkan: <table><tr><th>Dataset</th><th>MAE</th><th>RMSE</th><th>R²</th></tr><tr><td>Train</td><td>0.1976</td><td>0.4320</td><td>0.9404</td></tr><tr><td>Test</td><td>0.2101</td><td>0.4569</td><td>0.9332</td></tr></table> Perbedaan performa train dan test relatif kecil sehingga model Random Forest masih tergolong stabil dan belum menunjukkan overfitting yang signifikan. 2. Hasil XGBoost Regressor Selanjutnya dilakukan pelatihan menggunakan algoritma XGBoost dengan beberapa kombinasi parameter. <table><tr><th>Parameter</th><th>MAE</th><th>RMSE</th><th>R²</th></tr><tr><td>P1 (30 trees, depth=15)</td><td>0.1559</td><td>0.3107</td><td>0.9691</td></tr><tr><td>P2 (50 trees, depth=20)</td><td>0.1032</td><td>0.2410</td><td>0.9814</td></tr><tr><td>P3 (15 trees, depth=8)</td><td>0.4780</td><td>0.7441</td><td>0.8229</td></tr></table> Hasil terbaik diperoleh pada P2 dengan parameter n_estimators = 50 dan max_depth = 20. Model menghasilkan nilai MAE sebesar 0,1032, RMSE sebesar 0,2410, dan R² sebesar 0,9814. Nilai ini menunjukkan bahwa model XGBoost mampu menjelaskan sekitar 98,14% variasi data, sehingga performanya lebih baik dibanding Random Forest. Evaluasi train dan test pada XGBoost adalah sebagai berikut: <table><tr><th>Dataset</th><th>MAE</th><th>RMSE</th><th>R²</th></tr><tr><td>Train</td><td>0.0473</td><td>0.0853</td><td>0.9977</td></tr><tr><td>Test</td><td>0.1032</td><td>0.2410</td><td>0.9814</td></tr></table>	Parameter	MAE	RMSE	R ²	P1 (30 trees, depth=15)	0.3518	0.6299	0.8731	P2 (50 trees, depth=20)	0.2101	0.4569	0.9332	P3 (15 trees, depth=8)	0.6338	0.9497	0.7116	Dataset	MAE	RMSE	R ²	Train	0.1976	0.4320	0.9404	Test	0.2101	0.4569	0.9332	Parameter	MAE	RMSE	R ²	P1 (30 trees, depth=15)	0.1559	0.3107	0.9691	P2 (50 trees, depth=20)	0.1032	0.2410	0.9814	P3 (15 trees, depth=8)	0.4780	0.7441	0.8229	Dataset	MAE	RMSE	R ²	Train	0.0473	0.0853	0.9977	Test	0.1032	0.2410	0.9814
Parameter	MAE	RMSE	R ²																																																						
P1 (30 trees, depth=15)	0.3518	0.6299	0.8731																																																						
P2 (50 trees, depth=20)	0.2101	0.4569	0.9332																																																						
P3 (15 trees, depth=8)	0.6338	0.9497	0.7116																																																						
Dataset	MAE	RMSE	R ²																																																						
Train	0.1976	0.4320	0.9404																																																						
Test	0.2101	0.4569	0.9332																																																						
Parameter	MAE	RMSE	R ²																																																						
P1 (30 trees, depth=15)	0.1559	0.3107	0.9691																																																						
P2 (50 trees, depth=20)	0.1032	0.2410	0.9814																																																						
P3 (15 trees, depth=8)	0.4780	0.7441	0.8229																																																						
Dataset	MAE	RMSE	R ²																																																						
Train	0.0473	0.0853	0.9977																																																						
Test	0.1032	0.2410	0.9814																																																						

Selain itu, dilakukan pengecekan ulang dengan menghapus `building_id` yang terduga model terlalu bergantung pada variabel tersebut menggunakan model XGBoost dengan parameter terbaik:


```
xgb_check = XGBRegressor(  
    n_estimators=50,  
    max_depth=20,  
    random_state=42,  
    n_jobs=-1
```

Gambar 21. Pengecekan ulang


Hasil validasi ulang menghasilkan nilai: $R^2 = 0.9652$

Untuk memastikan model tidak terlalu bergantung pada identitas bangunan (`building_id`), dilakukan pengujian tambahan dengan menghapus variabel tersebut dari fitur pelatihan. Hasil menunjukkan nilai R^2 hanya mengalami penurunan kecil dari 0,9814 menjadi 0,9652, sehingga dapat disimpulkan bahwa performa model tidak semata-mata dipengaruhi oleh identitas bangunan, melainkan tetap mampu mempelajari pola konsumsi energi dari fitur lain seperti kondisi cuaca, karakteristik bangunan, dan faktor waktu. Dengan demikian, model dinilai memiliki kemampuan generalisasi yang baik.

Visualisasi grafik
latih dan validasi



Gambar 22. Visualisasi Parameter terbaik dari Random Forest



Gambar 23. Visualisasi Parameter terbaik dari XGboost

Temuan	<i>Berdasarkan hasil pelatihan model, ditemukan beberapa hal penting:</i> <i>1. XGBoost memberikan performa terbaik dibandingkan Random Forest pada seluruh metrik evaluasi. Hal ini terlihat dari nilai MAE dan RMSE yang lebih kecil serta nilai R^2 yang lebih tinggi.</i> <i>2. Pada model XGBoost terdapat indikasi overfitting ringan, karena performa data train sangat tinggi ($R^2 = 0.9977$) dibanding data test ($R^2 = 0.9814$). Namun selisih tersebut masih tergolong wajar karena performa data test tetap sangat baik dan stabil.</i> <i>3. Model Random Forest memiliki performa yang lebih stabil antara train dan test, tetapi akurasinya masih berada di bawah XGBoost.</i> <i>4. Hyperparameter tuning terbukti meningkatkan performa model secara signifikan. Kombinasi $n_estimators = 50$ dan $max_depth = 20$ menghasilkan performa terbaik pada kedua algoritma.</i> <i>5. Nilai R^2 yang mencapai lebih dari 0,9 menunjukkan bahwa fitur-fitur seperti kondisi cuaca, jenis bangunan, luas bangunan, serta informasi waktu berhasil membantu model dalam mempelajari pola konsumsi energi bangunan secara efektif.</i>
--------	--