

Laporan Kemajuan Proyek Pembelajaran Mesin


S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya

Kelas	2024 C
Ketua	Rebriane Atitha Ginting (24031554039)
Anggota 1	Nabilah Hilmi Rosanti (24031554053)
Anggota 2	Kekila Akmal Nifcky
URL Github	atithagt/UAS-Pembelajaran-Mesin-Kelompok-13

Informasi Umum Proyek

Judul	Prediksi Konsumsi Energi Bangunan Menggunakan Random Forest dan XGBoost untuk Mendukung Efisiensi Energi dalam Transisi Energi
Topik	Energi
Pilihan Rumusan Masalah	3.4. Pengembangan Inovasi dan Transformasi Bisnis dalam Transisi Energi
Revisi?	Ya / Tidak

Informasi Detil Dataset

Sumber dataset	Kaggle, ASHRAE - Great Energy Predictor III https://www.kaggle.com/c/ashrae-energy-prediction
Deskripsi awal fitur dataset	Dataset berisi data pembacaan meter energi bangunan per jam, metadata bangunan, dan data cuaca. File yang digunakan meliputi train.csv, building_metadata.csv, dan weather_train.csv. Target prediksi adalah meter_reading. Fitur dataset meliputi building_id, meter, timestamp, meter_reading, site_id, primary_use, square_feet, year_built, floor_count, air_temperature, cloud_coverage, dew_temperature, precip_depth_1_hr, sea_level_pressure, wind_direction, dan wind_speed.
EDA	Sebelum EDA, dataset awal yang berjumlah sekitar 20 juta baris disaring menjadi sekitar 9 juta baris sesuai kebutuhan analisis. Kami juga menerapkan memory reduction agar proses pengolahan data lebih efisien dan tidak membebani memori perangkat.  <pre>EDA print(df_full.shape) print(df_full.info()) (12060910, 16) <class 'pandas.DataFrame'> RangeIndex: 12060910 entries, 0 to 12060909 Data columns (total 16 columns): # Column Dtype --- - 0 building_id int16 1 meter int8 2 timestamp str 3 meter_reading float32 4 site_id int8 5 primary_use str 6 square_feet int32 7 year_built float32 8 floor_count float32 9 air_temperature float32 10 cloud_coverage float32 11 dew_temperature float32 12 precip_depth_1_hr float32 13 sea_level_pressure float32 14 wind_direction float32 15 wind_speed float32 dtypes: float32(10), int16(1), int32(1), int8(2), str(2) memory usage: 736.1 MB None</pre>

Gambar 1. Cek Data

Dari Gambar 1 terlihat bahwa data konsumsi energi, metadata bangunan, dan data cuaca digabungkan, diperoleh dataset sebanyak 12.060.910 baris dan 16 variabel. Analisis difokuskan pada konsumsi energi listrik dengan memilih meter = 0, karena listrik paling relevan dengan operasional bangunan modern, seperti AC, pencahayaan, dan perangkat elektronik. Dataset ini mencakup karakteristik bangunan serta kondisi cuaca yang berpotensi memengaruhi pola konsumsi energi.


```

floor_count      75.417883
year_built       53.644667
cloud_coverage   44.189468
precip_depth_1_hr 20.841537
sea_level_pressure 8.443666
wind_direction   5.627395
wind_speed       0.553814
dew_temperature  0.407026
air_temperature  0.392383
square_foot      0.000000
site_id          0.000000
primary_use      0.000000
meter            0.000000
timestamp        0.000000
building_id      0.000000
meter_reading    0.000000
dtype: float64


```

Gambar 2. Identifikasi Missing Value

Pada Gambar 2 terlihat hasil identifikasi missing value menunjukkan bahwa variabel `floor_count` memiliki data kosong tertinggi sebesar 75,4%, diikuti `year_built` sebesar 53,6%, dan `cloud_coverage` sebesar 44,2%. Variabel dengan missing value sangat tinggi seperti `floor_count` dipertimbangkan untuk dihapus, sedangkan `year_built` serta variabel cuaca dengan data hilang rendah, seperti `air_temperature`, `dew_temperature`, dan `wind_speed` (<1%), diimputasi menggunakan median agar distribusi data tetap stabil dan informasi penting tetap dipertahankan.



Gambar 3. Histogram Distribusi




Gambar 3. Histogram Log Distribusi

Gambar 3 menunjukkan histogram `meter_reading` dengan distribusi sangat right-skewed. Sebagian besar data berada pada konsumsi energi rendah, sedangkan sebagian kecil memiliki nilai sangat tinggi. Gambar 4 menunjukkan distribusi `meter_reading` setelah transformasi `log1p`. Hasilnya lebih stabil dan menyebar, sehingga transformasi log layak digunakan pada tahap preprocessing untuk mengurangi pengaruh nilai ekstrem.


	air_temperature	dew_temperature	wind_speed	sea_level_pressure
count	1.201358e+07	1.201182e+07	1.199412e+07	1.104253e+07
mean	1.600965e+01	8.334991e+00	3.559324e+00	1.016408e+03
std	1.039774e+01	9.836796e+00	2.317835e+00	7.035792e+00
min	-2.890000e+01	-3.500000e+01	0.000000e+00	9.682000e+02
25%	8.900000e+00	1.100000e+00	2.100000e+00	1.012100e+03
50%	1.670000e+01	9.400000e+00	3.100000e+00	1.016500e+03
75%	2.390000e+01	1.610000e+01	4.600000e+00	1.020700e+03
max	4.720000e+01	2.610000e+01	1.900000e+01	1.045500e+03

Gambar 5. Statistik Deskriptif Cuaca


Statistik deskriptif menunjukkan bahwa variabel cuaca cukup beragam. `air_temperature` memiliki median 16,7°C dengan rentang -28,9°C hingga 47,2°C, sedangkan `dew_temperature` memiliki median 9,4°C. `wind_speed` cenderung rendah dengan median 3,1, dan `sea_level_pressure` relatif stabil di sekitar 1016 hPa. Temuan ini menunjukkan bahwa data cuaca bersifat heterogen dan belum sepenuhnya merepresentasikan iklim tropis Indonesia.




Gambar 6. Histogram Distribusi Air



Gambar 7. Histogram Distribusi Dew



Gambar 8. Histogram Distribusi Sea





Gambar 9. Histogram Distribusi Wind

Gambar 6 hingga Gambar 9 menunjukkan distribusi variabel cuaca yang beragam. *air_temperature* dan *dew_temperature* terkonsentrasi pada suhu sedang, tetapi masih memiliki nilai ekstrem yang menunjukkan adanya wilayah non-tropis. *wind_speed* memiliki distribusi right-skewed, dengan mayoritas nilai berada pada kecepatan rendah hingga sedang. Sementara itu, *sea_level_pressure* relatif stabil dan terkonsentrasi di sekitar 1010–1020 hPa.


```
primary_use
Education      4597256
Office         2310203
Entertainment/public assembly 1511295
Public services 1320045
Lodging/residential 1229082
Other           210764
Parking         187447
Healthcare      184345
Warehouse/storage 103077
Retail           96618
Manufacturing/industrial 85216
Services        78951
Technology/science 45275
Food sales and service 43826
Utility          32476
Religious worship 25034
Name: count, dtype: int64
```

Gambar 10. Statistik Deskriptif *Primary_use*


Pada Gambar 10 terlihat bahwa distribusi *primary_use* didominasi oleh Education, lalu Office, Entertainment/Public Assembly, Public Services, dan Lodging/Residential. Hal ini menunjukkan bahwa dataset banyak merepresentasikan bangunan dengan aktivitas operasional tinggi dan penggunaan listrik rutin.



Gambar 11. Bar Chart Konsum Energi



Gambar 12. Line Chart Konsum Energi Jam



Gambar 13. Line Konsum Energi Bulan

Gambar 14. Bar Konsum Energi Hari

Gambar 11 hingga Gambar 14 menunjukkan bahwa konsumsi energi berbeda berdasarkan fungsi bangunan, jam, bulan, dan hari. Rata-rata konsumsi tertinggi terdapat pada kategori Healthcare, Education, Utility, dan Office karena aktivitas operasionalnya tinggi. Konsumsi juga meningkat pada siang hingga sore hari, naik pada pertengahan tahun terutama sekitar Agustus–September, serta cenderung lebih tinggi pada hari kerja dibanding akhir pekan. Pola ini menunjukkan bahwa penggunaan listrik dipengaruhi oleh jenis bangunan, waktu operasional, dan variasi musiman.

	meter_reading	floor_count	square_feet	air_temperature	dew_temperature	wind_speed	sea_level_pressure
meter_reading	1.000000	0.349708	0.522051	0.026839	0.043710	-0.019410	-0.007885
floor_count	0.349708	1.000000	0.505747	-0.297851	-0.256773	0.093124	-0.103812
square_feet	0.522051	0.505747	1.000000	0.015655	-0.014999	-0.042020	-0.047269
air_temperature	0.026839	-0.297851	0.015655	1.000000	0.283012	-0.019220	-0.248257
dew_temperature	0.043710	-0.256773	-0.014999	0.283012	1.000000	-0.110167	0.066523
wind_speed	-0.019410	0.093124	-0.042020	-0.019220	-0.110167	1.000000	-0.144317
sea_level_pressure	-0.007885	-0.103812	-0.047269	-0.248257	0.066523	-0.144317	1.000000

Gambar 15. Tabel Korelasi

Gambar 15 menunjukkan bahwa *square_feet* memiliki korelasi positif sedang terhadap *meter_reading* sebesar 0,55. Artinya, semakin besar luas bangunan, konsumsi energi cenderung semakin tinggi. Sementara itu, variabel cuaca memiliki korelasi linear yang lemah, sehingga pengaruhnya kemungkinan bergantung pada kombinasi faktor lain seperti waktu, jenis bangunan, dan aktivitas operasional.

Pada tahap preprocessing, dilakukan filtering suhu udara untuk menyesuaikan dataset dengan konteks iklim Indonesia. Filtering ini menggunakan variabel *air_temperature* dengan rentang 15–40°C agar data lebih relevan dengan karakteristik wilayah tropis.

Detil-detil
langkah
pre-processing

```
Pre-Processing

Filtering Relevansi Indonesia

df_full['air_temperature'].quantile(
    [0.01,0.05,0.10,0.25,0.50,0.75,0.90,0.95,0.99]
)

0.01    -10.000000
0.05     -1.700000
0.10     2.200000
0.25     8.900000
0.50    16.700001
0.75    23.900000
0.90    28.900000
0.95    31.700001
0.99    37.200001
Name: air_temperature, dtype: float32
```

Before : 12060910
After : 6739305
Remain : 55.88 %

Gambar 16. Hasil kuantil *air_temperature*.

Gambar 17. Hasil Filtering

Gambar 16 dan 17 menunjukkan hasil filtering *air_temperature* Nilai kuantil menunjukkan bahwa 1% data memiliki suhu di bawah -10°C , median suhu berada pada $16,7^{\circ}\text{C}$, dan 99% data berada di bawah $37,2^{\circ}\text{C}$. Temuan ini mengindikasikan bahwa sebagian besar data tidak sepenuhnya merepresentasikan kondisi iklim tropis Indonesia karena masih banyak observasi dengan suhu rendah khas wilayah beriklim

	<i>dingin. Oleh karena itu, pada tahap preprocessing dilakukan filtering suhu pada rentang 15–40°C agar dataset lebih relevan dengan karakteristik bangunan di Indonesia. Rentang tersebut dipilih untuk tetap mengakomodasi wilayah dataran tinggi Indonesia, namun mengurangi dominasi data dari wilayah non-tropis. Setelah filtering, sekitar 55,88% data atau sekitar 6,7 juta observasi tetap dipertahankan, sehingga dataset masih cukup besar untuk proses pemodelan.</i>
--	---

Kemajuan Pengerjaan

Teknik yang digunakan	<i>Proyek ini menggunakan teknik supervised learning dengan pendekatan regresi, karena target yang diprediksi berupa nilai numerik, yaitu meter_reading atau konsumsi energi listrik bangunan. Algoritma yang digunakan adalah Random Forest Regressor dan XGBoost Regressor. Random Forest digunakan sebagai model ensemble berbasis bagging, sedangkan XGBoost digunakan sebagai model ensemble berbasis boosting. Kedua algoritma ini dipilih karena cocok untuk data tabular, mampu menangani pola non-linear, serta dapat digunakan untuk membandingkan performa prediksi konsumsi energi bangunan.</i>
Nilai metrik terakhir	<i><u>Uraikan</u> nilai-nilai metrik yang sudah didapat dari proses-proses latih. Accuracy sudah berapa? F1 sudah berapa?</i>
Visualisasi grafik latih dan validasi	<i>Berikan plot latih atau validasi yang sudah didapat</i>
Temuan	<i>Uraikan temuan khusus (jika ada) pada proses latih, misal: ternyata terjadi overfitting atau underfitting. Proses latih-nya dilanjutkan dengan hyperparameter tuning</i>