

Laporan Akhir Proyek
Pembelajaran Mesin
S1 Sains Data, Fakultas Matematika Ilmu Pengetahuan dan IPA
Universitas Negeri Surabaya


Kelas	2024-C
Ketua	Rebriane Atitha Ginting (24031554039)
Anggota 1	Nabilah Hilmi Rosanti (24031554053)
Anggota 2	Kekila Akmal Nifcky (24031554144)
URL Github	atithagt/UAS-Pembelajaran-Mesin-Kelompok-13

Informasi Umum Proyek

Judul	<i>Prediksi Konsumsi Energi Bangunan Menggunakan Random Forest dan XGBoost untuk Mendukung Efisiensi Energi dalam Transisi Energi</i>
Topik	<i>Energi</i>
Pilihan Rumusan Masalah	<i>3.4. Pengembangan Inovasi dan Transformasi Bisnis dalam Transisi Energi</i>
Revisi?	<i>Ya / Tidak</i>

Pendahuluan	
Latar belakang (≥ 250 kata)	<i>Konsumsi energi pada sektor bangunan terus meningkat seiring berkembangnya gedung perkantoran, pusat perbelanjaan, rumah sakit, hotel, dan fasilitas pendidikan. Tingginya kebutuhan energi untuk pencahayaan, pendinginan, dan operasional bangunan dapat meningkatkan biaya operasional serta berpotensi menyebabkan pemborosan listrik apabila tidak dikelola secara efisien. Selain itu, peningkatan suhu udara akibat perubahan iklim turut mendorong kenaikan konsumsi energi, khususnya pada sistem pendingin ruangan (BMKG, 2025). Oleh karena itu, efisiensi energi pada sektor bangunan menjadi salah satu aspek penting dalam mendukung transisi energi yang berkelanjutan.</i> <i>Perkembangan teknologi machine learning memungkinkan prediksi konsumsi energi dilakukan berdasarkan data historis dan karakteristik bangunan. Metode ini mampu membantu mengidentifikasi pola penggunaan energi serta menghasilkan prediksi yang lebih akurat dibandingkan pendekatan konvensional (Ardabili et al., 2022). Informasi tersebut dapat dimanfaatkan untuk mendukung pengelolaan energi yang lebih efektif dan mengurangi potensi pemborosan energi pada bangunan.</i> <i>Penelitian ini menggunakan dataset ASHRAE yang memuat data konsumsi energi per jam, metadata bangunan, dan data cuaca (Miller et al., 2020). Sebelum proses pemodelan, dilakukan preprocessing dan seleksi fitur untuk memperoleh variabel yang paling relevan terhadap konsumsi energi bangunan. Algoritma yang digunakan adalah Random Forest Regressor dan XGBoost Regressor dengan beberapa kombinasi parameter untuk memperoleh model terbaik. Selain menghasilkan model prediksi, penelitian ini juga melakukan analisis Feature Importance dan SHAP untuk mengidentifikasi faktor-faktor yang paling memengaruhi konsumsi energi bangunan. Hasil penelitian diharapkan dapat menjadi referensi dalam pengembangan smart building, sistem monitoring energi, dan penerapan strategi efisiensi energi pada bangunan di Indonesia (Li et al., 2025).</i>

Rumusan masalah dan tujuan	<i>Rumusan Masalah:</i> 1. Bagaimana membangun model prediksi konsumsi energi bangunan menggunakan algoritma Random Forest Regressor dan XGBoost Regressor? 2. Bagaimana pengaruh preprocessing dan seleksi fitur terhadap kualitas prediksi konsumsi energi bangunan? 3. Bagaimana pengaruh variasi parameter pada algoritma Random Forest dan XGBoost terhadap performa prediksi konsumsi energi bangunan? 4. Algoritma dan kombinasi parameter manakah yang menghasilkan performa terbaik berdasarkan nilai MAE, RMSE, dan R²? 5. Fitur apa yang paling memengaruhi konsumsi energi bangunan berdasarkan hasil interpretasi model? <i>Tujuan:</i> 1. Membangun model prediksi konsumsi energi bangunan menggunakan algoritma Random Forest Regressor dan XGBoost Regressor. 2. Melakukan preprocessing dan seleksi fitur untuk memperoleh variabel yang paling relevan terhadap konsumsi energi bangunan. 3. Menganalisis pengaruh variasi parameter pada Random Forest dan XGBoost terhadap performa model. 4. Menentukan algoritma dan kombinasi parameter terbaik berdasarkan nilai MAE, RMSE, dan R². 5. Mengidentifikasi fitur-fitur yang paling berpengaruh terhadap konsumsi energi bangunan menggunakan feature importance dan SHAP. 6. Memberikan rekomendasi efisiensi energi berdasarkan hasil prediksi dan analisis faktor yang memengaruhi konsumsi energi bangunan.
Metodologi	
Ringkasan dataset	Penelitian ini menggunakan dataset ASHRAE Great Energy Predictor III yang tersedia pada kompetisi Kaggle ASHRAE Energy Prediction. Dataset merupakan hasil penggabungan data konsumsi energi bangunan (train.csv), metadata bangunan (building_metadata.csv), dan data cuaca (weather_train.csv). Dataset memuat informasi konsumsi energi per jam dari berbagai jenis bangunan yang tersebar pada beberapa lokasi dengan karakteristik bangunan dan kondisi cuaca yang beragam. Setelah dilakukan penggabungan dan filter target pada data, diperoleh dataset akhir sebanyak 12.060.910 observasi dengan 16 variabel, yang terdiri atas informasi konsumsi energi, karakteristik bangunan, serta kondisi cuaca. Dataset ini kemudian digunakan sebagai dasar dalam proses preprocessing, feature engineering, pemodelan Random Forest, dan XGBoost.
Alur penelitian	Alur Penelitian ini mengikuti tahapan yang divisualisasikan dalam flowchart. Secara garis besar, penelitian ini terdiri dari beberapa tahap utama yaitu mengurangi penggunaan memori, eksplorasi data, praproses data, penyetelan hyperparameter, pemilihan kombinasi parameter, evaluasi model, penentuan algoritma terbaik, analisis feature importance, dan analisis nilai SHAP. <i>Gambar 1. Alur Penelitian</i>



A. Reduksi Penggunaan Memori

Dataset ASHRAE memiliki jutaan baris sehingga membutuhkan kapasitas RAM yang sangat besar. Untuk mengatasi hal ini, dilakukan kompresi tipe data numerik menggunakan fungsi “reduce_mem_usage” yang mengonversi setiap fitur numerik ke tipe data terkecil yang masih mampu membaca rentang nilainya.

Untuk kolom yang bertipe integer, nilai minimum dan maksimum kolom dibandingkan dengan batas representasi masing-masing tipe data. Untuk kolom yang bertipe float, seluruh kolom dikonversi ke float32 jika seluruh nilai masuk dalam rentang representasi float32. Kompresi ini dapat mengurangi penggunaan memori secara signifikan tanpa mengubah informasi yang ada dalam data.

B. Penggabungan Dataset

Setelah ketiga dataset berhasil dimuat dan dikompresi, dilakukan penggabungan seara bertahap menggunakan operasi “left join”. Tahap pertama menggabungkan data train dengan data building melalui primary key yaitu “building_id”, sehingga setiap catatan konsumsi energi dilengkapi dengan informasi dari bangunan yang ada pada data tersebut. Tahap kedua menggabungkan hasil sebelumnya dengan data weather melalui kunci gabungan yaitu “site_id” dan “timestamp”, sehingga setiap catatan konsumsi energi juga dilengkapi dengan kondisi cuaca pada waktu yang bersesuaian. Hasil akhir penggabungan menghasilkan dataaset dengan 16 variabel yang mencakup informasi konsumsi energi, karakteristik bangunan, dan kondisi cuaca.

C. Hyperparameter Tuning

Kami memilih hyperparameter tuning menggunakan RandomizedSearchCV dari library scikit-learn. Metode ini menguji sejumlah kombinasi hyperparameter yang dipilih secara acak dari beberapa parameter yang telah ditentukan. Konfigurasi RandomizedSearchCV yang digunakan yaitu 20 kombinasi yang diuji dan 3-fold cross validation.

1. Ruang Parameter Random Forest

Untuk memperoleh kombinasi parameter yang optimal, dilakukan proses hyperparameter tuning pada algoritma Random Forest menggunakan metode pencarian parameter. Parameter yang diuji meliputi

n_estimators, *max_depth*, *min_samples_split*, *min_samples_leaf*, dan *max_features*.

Tabel 1. Ruang Parameter Random Forest

<i>Jenis Parameter</i>	<i>Nilai Yang Diuji</i>	<i>Alasan</i>
<i>n_estimators</i>	100	Nilai 100 dipilih karena cukup untuk menghasilkan model yang stabil tanpa meningkatkan waktu pelatihan secara berlebihan.
<i>max_depth</i>	12, 16, None	Nilai 12 dan 16 digunakan untuk membatasi kompleksitas model, sedangkan None memungkinkan pohon tumbuh hingga seluruh node murni sehingga dapat dibandingkan pengaruh kompleksitas model terhadap performa prediksi
<i>min_samples_split</i>	2, 5, 10	Nilai yang lebih besar membantu mengurangi risiko overfitting karena pohon tidak terlalu mudah membentuk cabang baru.
<i>min_samples_leaf</i>	1, 2, 4	Parameter ini digunakan untuk mencegah pembentukan leaf yang terlalu spesifik terhadap data pelatihan.
<i>max_features</i>	Sqrt, log2, 0.5	Variasi ini digunakan untuk mencari keseimbangan antara keberagaman pohon dan kemampuan model dalam menangkap pola data.

2. Ruang Parametrer XGBoost

Hyperparameter tuning pada algoritma XGBoost dilakukan menggunakan metode Randomized Search Cross Validation untuk memperoleh kombinasi parameter yang optimal. Parameter yang diuji meliputi *n_estimators*, *max_depth*, *learning_rate*, *subsample*, *colsample_bytree*, *reg_alpha*, dan *reg_lambda*.

Tabel 2. Ruang Parameter XGBoost

<i>Jenis Parameter</i>	<i>Nilai Yang Diuji</i>	<i>Alasan</i>
<i>n_estimators</i>	100	Nilai 100 dipilih karena cukup untuk menghasilkan model yang stabil tanpa meningkatkan waktu pelatihan secara berlebihan.
<i>max_depth</i>	6, 8, 10	Nilai <i>max_depth</i> dibatasi pada rentang 6 hingga 10 karena penelitian ini berfokus tidak hanya pada akurasi prediksi, tetapi juga pada interpretabilitas model. Nilai kedalaman yang terlalu tinggi berpotensi menyebabkan model menjadi terlalu kompleks dan meningkatkan risiko overfitting, sedangkan nilai yang terlalu rendah dapat menyebabkan model gagal menangkap pola penting pada data.
<i>learning_rate</i>	0.01, 0.05, 0.1	Nilai yang lebih kecil membuat proses pembelajaran lebih stabil, sedangkan nilai yang lebih besar mempercepat proses konvergensi model.
<i>subsample</i>	0.7, 0.8, 1.0	Nilai di bawah 1 digunakan untuk mengurangi risiko

				<i>overfitting dan meningkatkan kemampuan generalisasi model.</i>
		<i>colsample_bytree</i>	<i>0.7, 0.8, 1.0</i>	<i>Pengaturan ini bertujuan meningkatkan variasi antar pohon dan mengurangi ketergantungan model pada fitur tertentu.</i>
		<i>reg_alpha</i>	<i>0, 0.1, 0.5</i>	<i>Parameter regularisasi L1 yang digunakan untuk mengurangi kompleksitas model dengan mendorong beberapa bobot fitur menjadi nol. Nilai yang lebih besar menghasilkan model yang lebih sederhana.</i>
		<i>reg_lambda</i>	<i>0.5, 1.0, 2.0</i>	<i>Parameter regularisasi L2 yang digunakan untuk mengontrol besarnya bobot model sehingga dapat mengurangi overfitting dan meningkatkan kemampuan generalisasi.</i>
		Setiap kombinasi parameter dievaluasi menggunakan 3-fold cross-validation, di mana data latih dibagi menjadi tiga bagian dengan ukuran yang sama dan secara bergantian digunakan sebagai data validasi. Nilai rata-rata koefisien determinasi (Mean CV R²) dari ketiga fold digunakan sebagai kriteria dalam menentukan kombinasi parameter terbaik. Kombinasi parameter yang menghasilkan nilai Mean CV R² tertinggi dipilih sebagai parameter optimal untuk masing-masing model. D. Evaluasi Evaluasi model dilakukan menggunakan tiga metrik regresi yaitu Mean Absolute Error (MAE), Root Mean Squared Error (RMSE), Coefficient of Determination. 1. Mean Absolute Error (MAE) $MAE = \frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i $		

MAE mengukur rata-rata selisih absolut antara nilai aktual dan nilai prediksi. MAE lebih mudah diinterpretasikan karena memiliki satuan yang sama dengan variabel target. Semakin kecil nilai MAE, semakin baik performa model.

2. Root Mean Squared Error (RMSE)

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

RMSE memberikan penalti yang lebih besar terhadap kesalahan prediksi yang besar karena mengkuadratkan selisih sebelum dirata-ratakan. RMSE lebih sensitif terhadap outlier dibandingkan MAE, sehingga berguna untuk mendeteksi prediksi yang sangat meleset. Semakin kecil nilai RMSE, semakin baik performa model.

3. Koefisien Determinasi (R^2)

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

R^2 mengukur proporsi varians variabel target yang dapat dijelaskan oleh model. Nilai R^2 berkisar antara 0 hingga 1, di mana nilai yang mendekati 1 menunjukkan bahwa model mampu menjelaskan hampir seluruh variasi data. Semakin besar nilai R^2 , semakin baik kemampuan model dalam menjelaskan pola pada data.

4. Pemeriksaan Overfitting dan Underfitting

Untuk mendeteksi terjadinya overfitting atau underfitting, dilakukan perbandingan kinerja model pada data pelatihan (training set) dan data pengujian (test set) menggunakan nilai koefisien determinasi (R^2). Model dikategorikan mengalami overfitting apabila selisih antara nilai R^2 pada data latih dan data uji melebihi 0.05, yang menunjukkan bahwa model terlalu menyesuaikan diri dengan data pelatihan sehingga kemampuan generalisasinya menurun. Sebaliknya, model dikategorikan mengalami underfitting apabila nilai R^2 pada data uji kurang dari 0.70, yang mengindikasikan bahwa model belum mampu menangkap pola yang terdapat dalam data dengan baik. Jika model terdeteksi mengalami overfitting, proses pengembangan model dikembalikan ke tahap penyetelan hyperparameter dengan memperketat kompleksitas model, misalnya melalui pengurangan nilai max_depth, peningkatan regularisasi, atau penyesuaian parameter lainnya agar model mampu melakukan generalisasi dengan lebih baik.

E. Feature Importance

Analisis feature importance dilakukan untuk mengidentifikasi fitur-fitur yang paling berpengaruh dalam proses prediksi konsumsi energi bangunan. Informasi ini digunakan untuk memahami faktor utama yang memengaruhi konsumsi energi berdasarkan hasil model yang telah dibangun. Pada penelitian ini, analisis feature importance dilakukan pada model Random Forest dan XGBoost karena kedua algoritma tersebut termasuk metode berbasis pohon keputusan (tree-based ensemble) yang mampu menghitung kontribusi relatif setiap fitur terhadap hasil prediksi.

Pada Random Forest, nilai feature importance dihitung menggunakan pendekatan Mean Decrease in Impurity (MDI). Metode ini mengukur seberapa besar suatu fitur mampu mengurangi impurity atau ketidakmurnian data ketika digunakan untuk melakukan pemisahan (split) pada pohon

	keputusan. Semakin besar penurunan impurity yang dihasilkan oleh suatu fitur pada seluruh pohon dalam ensemble, maka semakin tinggi nilai feature importance fitur tersebut. Nilai importance kemudian dinormalisasi sehingga total kontribusi seluruh fitur bernilai satu. Pada XGBoost, feature importance dihitung menggunakan metrik gain, yaitu rata-rata peningkatan performa model yang diperoleh setiap kali suatu fitur digunakan untuk melakukan split pada pohon keputusan. Fitur dengan nilai gain yang tinggi menunjukkan bahwa fitur tersebut memberikan kontribusi besar dalam mengurangi error prediksi. Oleh karena itu, semakin besar nilai gain suatu fitur, semakin penting peran fitur tersebut dalam proses prediksi konsumsi energi bangunan. Hasil feature importance divisualisasikan menggunakan diagram batang (bar chart) untuk menampilkan peringkat fitur berdasarkan kontribusinya terhadap model. Fitur dengan nilai importance tertinggi diinterpretasikan sebagai faktor yang paling berpengaruh terhadap konsumsi energi bangunan. <i>F. Analisis SHAP values</i> SHapley Additive exPlanations (SHAP) merupakan metode interpretabilitas model yang digunakan untuk menjelaskan kontribusi setiap fitur terhadap hasil prediksi model. Metode ini dikembangkan berdasarkan konsep Shapley Value dari teori permainan kooperatif (cooperative game theory), yang membagi kontribusi setiap fitur secara adil terhadap prediksi yang dihasilkan model. Dibandingkan feature importance konvensional, SHAP mampu memberikan informasi tidak hanya mengenai tingkat kepentingan fitur secara global, tetapi juga arah dan besaran pengaruh setiap fitur terhadap prediksi individual. Pada penelitian ini, SHAP digunakan untuk menginterpretasikan model XGBoost yang memiliki performa terbaik dalam memprediksi konsumsi energi bangunan. Perhitungan nilai SHAP dilakukan menggunakan library SHAP dengan metode TreeExplainer, yang dioptimalkan untuk model berbasis pohon keputusan (tree-based models). Mengingat ukuran dataset yang sangat besar, proses perhitungan SHAP dilakukan pada sebagian data uji yang dipilih secara representatif untuk mengurangi beban komputasi tanpa mengurangi kualitas interpretasi model. Hasil analisis SHAP divisualisasikan menggunakan dua jenis visualisasi. Pertama, SHAP Bar Plot yang menampilkan rata-rata nilai absolut SHAP (mean absolute SHAP value) untuk menunjukkan tingkat kepentingan setiap fitur secara global. Kedua, SHAP Beeswarm Plot yang menampilkan distribusi nilai SHAP setiap fitur sehingga dapat digunakan untuk menganalisis arah pengaruh fitur terhadap prediksi konsumsi energi bangunan. Melalui analisis ini, dapat diidentifikasi faktor-faktor yang paling berpengaruh terhadap konsumsi energi serta bagaimana masing-masing faktor meningkatkan atau menurunkan nilai prediksi yang dihasilkan model.
Proses wrangling	<i>A. Filtering Relevansi Indonesia</i> Karena dataset kami mencakup data dari berbagai iklim di dunia, dilakukan filtering berdasarkan rentang suhu udara untuk meningkatkan relevansi terhadap cuaca di Indonesia. Batas yang dipilih adalah 15 hingga 40 derajat celcius, dengan pertimbangan berdasarkan data dari BMKG dan analisis distribusi data. Berdasarkan data dari BMKG menjelaskan bahwa mayoritas wilayah Indonesia memiliki suhu rata-rata 25 derajat celcius. Batas bawah

mewakilkkan wilayah dataran tinggi seperti Dieng dan Jaya Wijaya. Batas atas mewakili kondisi panas ekstrem di wilayah Timur Indonesia.

Selain mempertimbangkan literatur, pemilihan batas bawah juga mengacu pada distribusi data hasil eksplorasi. Analisis quantile menunjukkan bahwa median temperatur dataset hanya sebesar 16,7°C, yang berarti sekitar 50% observasi memiliki suhu di bawah 16,7°C. Kondisi ini dinilai kurang representatif terhadap karakteristik iklim Indonesia yang didominasi wilayah tropis hangat, karena daerah dengan suhu rendah di Indonesia relatif terbatas dan hanya terjadi pada wilayah tertentu seperti pegunungan atau dataran tinggi. Oleh karena itu, dipilih batas bawah 15°C sebagai kompromi agar tetap mengakomodasi wilayah dingin Indonesia, namun sekaligus mengurangi dominasi observasi dari wilayah beriklim dingin non-Indonesia yang tidak relevan dengan tujuan penelitian. Dengan filtering ini, sekitar 55,88% observasi ($\pm 6,7$ juta data) tetap dipertahankan sehingga dataset masih cukup besar untuk proses pemodelan.

B. Seleksi Fitur

Dilakukan penyeleksian fitur dengan beberapa pertimbangan, salah satunya dari proporsi missing value pada beberapa variabel.

Tabel 3. Proporsi Missing Value

Variaabel	Proporsi
Floor_Count	79.002
Year_build	53.660
Cloud_Coverage	41.111
Precip_depth_1_hr	12.269
Wind_direction	7.563
Sea_level_pressure	4.696
Wind_speed	0.242
Dew_temperature	0.013

Dilakukan Penghapusan variabel `wind_direction`, `floor_count`, `building_id`, dan `site_id` dengan pertimbangan yang berbeda. Variabel `wind_direction` dihapus karena dinilai kurang memberikan kontribusi yang signifikan terhadap prediksi konsumsi energi bangunan dan memiliki relevansi yang lebih rendah dibanding variabel cuaca lainnya, seperti suhu udara, kecepatan angin, maupun tekanan udara. Variabel `floor_count` dihapus karena memiliki proporsi missing value yang sangat tinggi sehingga berpotensi menurunkan kualitas pemodelan apabila dipertahankan. Sementara variabel `bulding_id` dan `site_id` dihapus karena itu bukan fitur prediktif namun sebagai identifier. Penghapusan `building_id` dan `site_id` dilakukan agar model lebih berfokus pada faktor yang memengaruhi konsumsi energi, seperti karakteristik bangunan, waktu, dan kondisi lingkungan.

C. Feature Engineering

Pada tahap feature engineering, dilakukan ekstraksi informasi waktu dari variabel `timestamp` dengan membentuk fitur baru berupa `hour`, `dayofweek`, dan `month`. Fitur `hour` digunakan untuk menangkap pola konsumsi energi berdasarkan jam penggunaan bangunan, `dayofweek` untuk membedakan pola

	konsumsi antara hari kerja dan akhir pekan, serta month untuk menangkap pola musiman atau perubahan konsumsi energi berdasarkan periode waktu tertentu. Proses ini dilakukan agar model dapat mengenali pola temporal yang berpotensi memengaruhi konsumsi energi bangunan. D. Encoding Variabel Kategorikal Variabel <code>primary_use</code> yang bersifat kategorikal dikonversi ke format numerik menggunakan “One-Hot Encoing”. Metode ini membuat fitur biner baru untuk setiap kategori bangunan, sehingga menghasilkan 16 kolom tambahan yang merepresentasikan kategori seperti Education, Office, Healthcare, Parking, dan lainnya. Parameter “<code>drop_first = False</code>” digunakan agar semua kategori terwakili yang dimana penting untuk analisis feature importance dan SHAP value. Algoritma Random Forest dan XGBoost tidak terpengaruh oleh multikolinearitas yang mungkin timbul dikarenakan proses encoding ini. E. Transformasi Variabel Target Variabel Target ditransfoormasi menggunakan fungsi logaritma dengan penambahan kkonstanta 1 (<code>log1p</code>). Transformasi ini dilakukan karena distribusi target sangat right skewed dengan rentang nilai yang besar serta banyak nilai nol. Penggunaan transformasi log membantu mengurangi pengaruh nilai ekstrem (outlier) dan membuat distribusi target menjadi lebih stabil. F. Pemisahan Fiitur Target Seluruh variabel prediktor (<i>X</i>) dipisahkan dari variabel target (<i>y</i>). Variabel <code>meter_reading</code> dan <code>meter_reading_log</code> dihapus dari <i>X</i> untuk mencegah data leakage. Data kemudian dibagi menjadi data latih (training set) dan data uji (test set) dengan rasio 80:20 menggunakan fungsi <code>train test split</code> dari library <code>scikit-learn</code>.
Temuan	Berdasarkan keseluruhan proses yang telah dilakukan mulai dari reduksi memori, penggabungan dataset, preprocessing, feature engineering, hyperparameter tuning, hingga evaluasi model, diperoleh sejumlah temuan penting yang merangkum kontribusi metodologis penelitian ini. Penerapan batas suhu 15–40°C berhasil mempertahankan sekitar 55,88% observasi ($\pm 6,7$ juta data). Filtering ini terbukti efektif dalam meningkatkan relevansi model terhadap kondisi iklim tropis Indonesia tanpa mengorbankan ukuran dataset yang memadai untuk pemodelan. Penghapusan variabel <code>floor_count</code> (79% missing), <code>wind_direction</code> (relevansi rendah), serta <code>building_id</code> dan <code>site_id</code> (identifier) terbukti tidak menurunkan performa model. Hal ini menunjukkan bahwa variabel-variabel tersebut memang tidak memberikan kontribusi signifikan terhadap prediksi konsumsi energi. Distribusi <code>meter_reading</code> yang sangat right-skewed dan mengandung banyak nilai nol diatasi dengan transformasi <code>log1p</code>. Hasilnya adalah distribusi target yang lebih simetris sehingga memudahkan algoritma regresi dalam mempelajari pola data.
Hasil dan Pembahasan	
Hasil eksplorasi data	Tahap pertama adalah memisahkan data menjadi feature (<i>X</i>) dan target (<i>y</i>). Feature (<i>X</i>) berisi seluruh variabel prediktor yang digunakan untuk memprediksi konsumsi energi, sedangkan target (<i>y</i>) adalah <code>meter_reading_log</code>. Variabel <code>meter_reading</code> dan <code>meter_reading_log</code> dihapus dari feature untuk menghindari data leakage, yaitu kondisi ketika model memperoleh informasi target secara langsung sehingga menghasilkan performa yang bias. Dataset kemudian dibagi menjadi data latih dan data uji dengan proporsi 80:20, menghasilkan 5.391.444 data latih dan 1.347.861 data uji dengan total 28 fitur. A. Pemodelan Random Forest dengan Randomized Search

Pada penelitian ini, algoritma Random Forest Regressor digunakan untuk memprediksi konsumsi energi bangunan. Untuk memperoleh kombinasi parameter yang optimal, dilakukan proses pencarian parameter menggunakan Randomized Search Cross Validation.

Parameter yang diuji meliputi:

1. *n_estimators* untuk menentukan jumlah pohon yang dibangun.
2. *max_depth* untuk mengontrol kedalaman maksimum pohon.
3. *min_samples_split* untuk menentukan jumlah minimum sampel sebelum node dapat dipecah.
4. *min_samples_leaf* untuk menentukan jumlah minimum sampel pada setiap daun.
5. *max_features* untuk menentukan jumlah fitur yang digunakan pada setiap proses pemisahan node.

Parameter-parameter tersebut dipilih karena memiliki pengaruh langsung terhadap kompleksitas model, kemampuan generalisasi, dan risiko overfitting.

Tabel 4. Hasil Parameter Terbaik Random Forest

Parameter	Nilai Terbaik
<i>n_estimators</i>	100
<i>max_depth</i>	12
<i>min_samples_split</i>	5
<i>min_samples_leaf</i>	2
<i>max_features</i>	0.5

Best CV $R^2 = 0.77996$

Hasil tersebut menunjukkan bahwa model terbaik diperoleh dengan kedalaman pohon yang dibatasi pada nilai 12 serta penggunaan 50% fitur pada setiap proses split. Pengaturan tersebut membantu model menangkap pola data tanpa menjadi terlalu kompleks sehingga mampu menjaga kemampuan generalisasi.

Tabel 5. Kombinasi Parameter Terbaik Random Forest

Peringkat	Mean CV R^2	Std CV R^2
1	0,7800	0,0004
2	0,7797	0,0014
3	0,7490	0,0005
4	0,7490	0,0004
5	0,7473	0,0009

Berdasarkan hasil Randomized Search, lima kombinasi parameter terbaik menghasilkan nilai Cross Validation R^2 yang relatif berdekatan, yaitu berkisar antara 0,7473 hingga 0,7800.

Temuan yang dapat diperoleh adalah:

1. Seluruh kombinasi terbaik menggunakan 100 pohon (*n_estimators* = 100) yang menunjukkan jumlah pohon tersebut sudah cukup untuk menghasilkan prediksi yang stabil.
2. Nilai *min_samples_split* = 5 dan *min_samples_leaf* = 2 sering muncul pada peringkat atas, menunjukkan bahwa pembatasan jumlah sampel minimum membantu mengurangi overfitting.

3. Kedalaman pohon yang tidak terlalu besar menghasilkan performa yang lebih baik dibandingkan pohon yang sangat dalam.
4. Perbedaan nilai R^2 antar lima kombinasi terbaik relatif kecil sehingga model Random Forest cukup stabil terhadap perubahan parameter.
5. Kombinasi terbaik menghasilkan Mean CV R^2 sebesar 0,7800, yang berarti model mampu menjelaskan sekitar 78% variasi konsumsi energi pada data validasi.

B. Pemodelan XGBoost dengan Randomized Search

Selain Random Forest, penelitian ini menggunakan algoritma XGBoost Regressor yang dikenal memiliki kemampuan tinggi dalam menangani data berukuran besar dan hubungan nonlinier.

Proses optimasi dilakukan menggunakan Randomized Search pada beberapa parameter utama, yaitu:

1. *n_estimators* untuk menentukan jumlah boosting tree.
2. *max_depth* untuk mengontrol kompleksitas model.
3. *learning_rate* untuk mengatur kecepatan pembelajaran.
4. *subsample* untuk menentukan proporsi data yang digunakan setiap iterasi.
5. *colsample_bytree* untuk menentukan proporsi fitur yang digunakan.
6. *reg_alpha* untuk regularisasi L1.
7. *reg_lambda* untuk regularisasi L2.

Parameter tersebut dipilih karena berpengaruh langsung terhadap akurasi model, kemampuan generalisasi, serta pengendalian overfitting.

Tabel 6. Hasil Parameter Terbaik XGBoost

Parameter	Nilai Terbaik
<i>n_estimators</i>	100
<i>max_depth</i>	10
<i>learning_rate</i>	0.1
<i>subsample</i>	0.8
<i>colsample_bytree</i>	1.0
<i>reg_alpha</i>	0
<i>reg_lambda</i>	2.0

Best CV $R^2 = 0.86750$

Hasil tersebut menunjukkan bahwa model terbaik diperoleh dengan penggunaan seluruh fitur pada setiap pohon, proporsi data sebesar 80% untuk setiap iterasi boosting, serta regularisasi L2 yang cukup kuat untuk menjaga stabilitas model.

Tabel 7. Kombinasi Parameter Terbaik XGBoost

Peringkat	Mean CV R^2	Std CV R^2
1	0.8675	0.0010
2	0.8648	0.0025
3	0.8641	0.0015
4	0.8279	0.0005
5	0.8022	0.0043

Berdasarkan hasil Randomized Search, lima kombinasi parameter terbaik menghasilkan nilai Mean CV R^2 antara 0,8022 hingga 0,8675.

Beberapa temuan yang diperoleh adalah:

1. Seluruh kombinasi terbaik menghasilkan performa yang lebih tinggi dibandingkan Random Forest.
2. Nilai subsample 0,8 sering muncul pada peringkat atas yang menunjukkan bahwa penggunaan sebagian data pada setiap iterasi mampu meningkatkan generalisasi model.
3. Nilai reg_lambda yang relatif tinggi membantu mengurangi risiko overfitting.
4. Kombinasi max_depth = 10 dan learning_rate = 0,1 memberikan keseimbangan yang baik antara kemampuan belajar dan stabilitas model.
5. Kombinasi terbaik menghasilkan Mean CV R² sebesar 0,8675, yang berarti model mampu menjelaskan sekitar 86,75% variasi konsumsi energi pada data validasi.

C. Evaluasi Model Random Forest


Tabel 8. Hasil Evaluasi model Random Forest

Dataset	MAE	RMSE	R²
<i>Train</i>	0.5437	0.8256	0.7824
<i>Test</i>	0.5448	0.8273	0.7811

$\Delta R^2 = 0,0013$ (Aman)

Berdasarkan hasil evaluasi, model Random Forest menghasilkan nilai R² sebesar 0,7811 pada data uji. Nilai tersebut menunjukkan bahwa model mampu menjelaskan sekitar 78,11% variasi konsumsi energi bangunan. Perbedaan nilai R² antara data latih dan data uji sangat kecil (0,0013), sehingga model tidak mengalami overfitting dan mampu melakukan generalisasi dengan baik pada data baru.

Gambar 2. Visualisasi Actual vs predicted Random Forest



Pada Gambar 2 terlihat bahwa sebagian besar titik prediksi mengikuti garis ideal ($y = x$). Hal ini menunjukkan bahwa model mampu memprediksi konsumsi energi dengan cukup baik. Namun, masih terdapat beberapa titik yang menyebar jauh dari garis ideal terutama pada nilai konsumsi energi yang tinggi, sehingga akurasi model masih dapat ditingkatkan.

D. Evaluasi Model XGBOOST


Tabel 9. Hasil Evaluasi XGBoost

Dataset	MAE	RMSE	R ²
Train	0.3982	0.6399	0.8693
Test	0.3999	0.6430	0.8678

$$\Delta R^2 = 0,0015 \text{ (Aman)}$$

Model XGBoost menghasilkan nilai R^2 sebesar 0,8678 pada data uji. Hasil ini menunjukkan bahwa model mampu menjelaskan sekitar 86,78% variasi konsumsi energi bangunan. Selisih nilai R^2 antara data latih dan data uji hanya 0,0015, sehingga model tidak mengalami overfitting dan memiliki kemampuan generalisasi yang baik.

Gambar 3. Visualisasi Actual vs predicted XGBoost



Pada Gambar 3 terlihat bahwa titik-titik prediksi XGBoost lebih rapat mengikuti garis ideal dibandingkan Random Forest. Penyebaran titik yang lebih kecil menunjukkan bahwa model memiliki tingkat akurasi yang lebih tinggi dan mampu memprediksi konsumsi energi dengan lebih konsisten.

E. Feature Importance

Analisis Feature Importance dilakukan untuk mengetahui fitur yang paling berkontribusi dalam proses prediksi konsumsi energi bangunan.

1. Random Forest

Tabel 10. Top 5 Feature Importance Random Forest

Peringkat	Fitur	Importance
1	square_feet	0.5883
2	year_built	0.1419
3	month	0.0843
4	dew_temperature	0.0460

5

primary_use_Education

0.0216

Berdasarkan tabel Random Forest, square_feet menjadi fitur paling penting dengan kontribusi sebesar 58,83%, jauh lebih tinggi dibandingkan fitur lainnya. Hal ini menunjukkan bahwa luas bangunan memiliki hubungan yang kuat dengan konsumsi energi. Selain itu, faktor waktu (month) dan karakteristik bangunan (year_built) juga berperan dalam memengaruhi penggunaan energi.


2. XGBOOST

Tabel 11. Top 5 Feature Importance

Peringkat	Fitur	Importance
1	primary_use_Parking	0.3345
2	primary_use_Other	0.0746
3	square_feet	0.0693
4	primary_use_Services	0.0571
5	primary_use_Lodging/residential	0.0468

Pada XGBoost, fitur primary_use_Parking memiliki nilai importance tertinggi. Namun, hasil feature importance pada XGBoost hanya menunjukkan seberapa penting fitur digunakan dalam pembentukan pohon keputusan, sehingga belum dapat digunakan sebagai dasar utama untuk menentukan faktor yang paling memengaruhi konsumsi energi. Oleh karena itu diperlukan analisis lanjutan menggunakan SHAP.

Gambar 4. Visualisasi Feature Importance



Gambar 4 menunjukkan bahwa Random Forest lebih banyak memanfaatkan fitur numerik seperti square_feet dan year_built, sedangkan XGBoost lebih banyak memanfaatkan kategori fungsi bangunan (primary_use) dalam proses prediksi. Perbedaan ini menunjukkan bahwa kedua algoritma memiliki cara yang berbeda dalam mempelajari pola data.

Gambar 5. Visualisasi Cumulative Feature Importance

	Berdasarkan Gambar 5, Random Forest hanya membutuhkan 3 fitur untuk mencapai 80% cumulative importance, sedangkan XGBoost membutuhkan 11 fitur. Hal ini menunjukkan bahwa Random Forest lebih bergantung pada beberapa fitur dominan, sementara XGBoost memanfaatkan lebih banyak fitur dalam proses prediksi. Hasil feature selection ini digunakan untuk mengurangi kompleksitas data, mempercepat proses pelatihan model, dan mempertahankan fitur-fitur yang memiliki kontribusi terbesar terhadap konsumsi energi bangunan.
Hasil eksperimen	Pada penelitian ini dilakukan proses pelatihan dan validasi menggunakan dua algoritma, yaitu Random Forest Regressor dan XGBoost Regressor. Sebelum proses pelatihan, data telah melalui tahap preprocessing, feature selection, serta pembagian data menjadi data latih (training set) dan data uji (testing set) dengan proporsi 80:20. Untuk memperoleh model terbaik, dilakukan pengujian beberapa kombinasi parameter menggunakan Randomized Search Cross Validation. Setiap kombinasi parameter dievaluasi menggunakan nilai Cross Validation R^2, kemudian dipilih kombinasi yang menghasilkan performa terbaik untuk masing-masing algoritma. Pada algoritma Random Forest, kombinasi parameter terbaik menghasilkan Best CV R^2 sebesar 0,7800. Setelah dilakukan pelatihan menggunakan parameter tersebut, model memperoleh MAE sebesar 0,5448, RMSE sebesar 0,8273, dan R^2 sebesar 0,7811 pada data uji. Selisih nilai R^2 antara data latih (0,7824) dan data uji (0,7811) hanya sebesar 0,0013, sehingga model tidak mengalami overfitting dan mampu melakukan generalisasi dengan baik. Pada algoritma XGBoost, kombinasi parameter terbaik menghasilkan Best CV R^2 sebesar 0,8675. Hasil evaluasi menunjukkan MAE sebesar 0,3999, RMSE sebesar 0,6430, dan R^2 sebesar 0,8678 pada data uji. Selisih nilai R^2 antara data latih (0,8693) dan data uji (0,8678) hanya sebesar 0,0015, yang menunjukkan bahwa model juga tidak mengalami overfitting. Berdasarkan hasil tersebut, XGBoost menghasilkan performa yang lebih baik dibandingkan Random Forest karena memiliki nilai MAE dan RMSE yang lebih rendah, serta R^2 yang lebih tinggi. Hal ini menunjukkan bahwa XGBoost mampu memprediksi konsumsi energi bangunan dengan tingkat akurasi yang lebih baik dan kesalahan prediksi yang lebih kecil. Oleh karena itu, XGBoost dipilih sebagai model terbaik untuk tahap interpretasi fitur menggunakan Feature Importance dan SHAP.
Kesimpulan dan Saran	
Kesimpulan	Penelitian ini secara langsung menjawab rumusan masalah yang telah ditetapkan melalui pembangunan model prediksi konsumsi energi bangunan berbasis machine learning. Model Random Forest Regressor dan XGBoost Regressor berhasil dibangun dengan performa yang baik, di mana XGBoost terpilih sebagai model

	terbaik dengan $R^2 = 0,8678$, $MAE = 0,3999$, dan $RMSE = 0,6430$ pada data uji. Hasil ini menunjukkan bahwa pendekatan machine learning mampu memprediksi konsumsi energi bangunan secara akurat, sehingga berkontribusi langsung dalam mendukung pengelolaan energi yang lebih efisien sebagai bagian dari transisi energi berkelanjutan di Indonesia. Terkait pengaruh preprocessing dan seleksi fitur, penelitian ini membuktikan bahwa tahapan tersebut memberikan dampak yang signifikan terhadap kualitas prediksi. Filtering relevansi Indonesia, penghapusan variabel dengan missing value tinggi, transformasi log1p pada target, serta feature engineering temporal secara bersama-sama menghasilkan dataset yang lebih bersih dan representatif. Hasilnya, kedua model mampu belajar dari pola data yang lebih konsisten sehingga menghasilkan prediksi yang lebih andal. Variasi parameter pada kedua algoritma juga terbukti berpengaruh terhadap performa, dan melalui Randomized Search Cross Validation diperoleh kombinasi parameter optimal yang menjaga keseimbangan antara akurasi dan kemampuan generalisasi, tanpa mengalami overfitting pada kedua model. Dari sisi temuan yang dapat dimanfaatkan oleh masyarakat, penelitian ini mengidentifikasi bahwa luas bangunan (square feet) adalah faktor paling dominan yang memengaruhi konsumsi energi, disusul oleh tahun pembangunan, bulan, serta jenis penggunaan bangunan. Temuan ini memiliki nilai praktis yang tinggi yaitu pengelola gedung dan pemilik bangunan dapat memprioritaskan efisiensi energi pada bangunan berukuran besar dan bangunan tua yang cenderung memiliki konsumsi energi lebih tinggi. Selain itu, perbedaan pola konsumsi antar jenis bangunan seperti parkir, layanan, dan pendidikan menunjukkan bahwa strategi penghematan energi perlu disesuaikan dengan fungsi bangunan, bukan diterapkan secara seragam. Secara lebih luas, model prediksi yang dihasilkan dapat menjadi pondasi bagi pengembangan sistem monitoring energi otomatis pada gedung-gedung di Indonesia, mendukung perencanaan kebijakan efisiensi energi berbasis data, serta menjadi referensi dalam perancangan bangunan baru yang lebih hemat energi sejak tahap awal pembangunan.
Saran	- Validasi model pada data bangunan nyata di Indonesia. Model yang telah dibangun perlu divalidasi menggunakan data tagihan listrik aktual dari berbagai jenis gedung di Indonesia untuk mengukur sejauh mana akurasi prediksi yang diperoleh dalam penelitian ini dapat dipertahankan pada kondisi nyata di lapangan. - Pengembangan dashboard interaktif untuk pengelola gedung. Hasil model dapat dikemas dalam antarmuka yang mudah digunakan oleh pengelola gedung non-teknis, lengkap dengan visualisasi tren konsumsi energi, prediksi kedepan, dan rekomendasi tindakan efisiensi yang dipersonalisasi berdasarkan karakteristik masing-masing gedung.
Daftar Pustaka	
Daftar Pustaka	Ardabili, S., Abdolalizadeh, L., Mako, C., Torok, B., & Mosavi, A. (2022, March 18). Systematic Review of Deep Learning and Machine Learning for Building Energy. <i>Frontiers</i>, 10. https://doi.org/10.3389/fenrg.2022.786027 Li, D., Qi, Z., Zhou, Y., & Elchalakani, M. (2025, February 19). Machine Learning Applications in Building Energy Systems: Review and Prospects. <i>MDPI</i>, 15 No 4. https://doi.org/10.3390/buildings15040648 Lundberg, S., & Lee, S.-I. (2017, November 25). A Unified Approach to Interpreting Model Predictions. <i>arXiv</i>, (2). https://doi.org/10.48550/arXiv.1705.07874 Miller, C., Arjunan, P., Fu, C., & Roth, J. (2020, August 24). The ASHRAE Great Energy Predictor III competition: Overview and results. <i>www.tandfonline.com/</i>, 26, 1427-1447. https://doi.org/10.1080/23744731.2020.1795514

	Miller, C., Kathirgamathan, A., Picchetti, B., Arjunan, P., & Park, J. Y. (2020, October 27). The Building Data Genome Project 2, energy meter data from the ASHRAE Great Energy Predictor III competition. <i>www.nature.com</i>, 368. https://doi.org/10.1038/s41597-020-00712-x Miller, C., Picchetti, B., Fu, C., & Pantelic, J. (2022, May 3). Limitations of machine learning for building energy prediction: ASHRAE Great Energy Predictor III Kaggle competition error analysis. <i>www.tandfonline.com</i>, 28, 610-627. https://doi.org/10.1080/23744731.2022.2067466 Prasetyaningtyas, K. (2026, Februari 6). <i>Anomali Suhu Udara Rata-Rata Tahun 2025</i>. BMKG. https://www.bmkg.go.id/iklim/anomali-suhu-udara/anomali-suhu-udara-rata-rata-tahun-2025 Shapi, M. K. M., Ramli, N. A., & Awal, L. J. (2021, March). Energy consumption prediction by using machine learning for smart building: Case study in Malaysia. <i>Developments in the Built Environment</i>, 5(100037). https://doi.org/10.1016/j.dibe.2020.100037
--	--